ChatGPT

合成データ生成と二点連結判定問題の文献調査レポート

エグゼクティブサマリ

本課題は、画像中に与えられた二点が**同一の連結成分に属するか**を判定する二値分類問題として定式化できるが、実際には単純な局所パターン認識では足りず、**細い領域・高曲率・長距離の依存関係・交差や近接による錯視**をまたぐグローバルな推論が必要になる。Pathfinder 系タスクはまさに「二点が破線のパスで繋がっているか」を問うベンチマークであり、LRA はこの種の長距離空間依存性を評価する代表的枠組みとして広く参照されている。一方で、Pathfinder や LRA をめぐっては、再帰やフィードバックが有利だとする研究と、適切に設計された CNN でも高難度版を解けるとする研究の双方があり、**「CNN は必ず苦手」と断言するより、設計とデータ条件に強く依存する**という理解が妥当である。ただし、局所受容野中心の設計では高度な連結性を落としやすいという問題意識自体は、多くのトポロジー保存型セグメンテーション研究で共有されている。 [1]

既存研究の整理としては、少なくとも五つの系譜を統合して見るべきである。第一に、**グラフ連結性と最短経路**で、画像をピクセルグラフまたはスケルトングラフに変換して厳密判定する系譜。第二に、**形態学・細線化**で、opening/closing・連結成分ラベリング・Hilditch 型の細線化などを使って接続構造を抽出する系譜。第三に、**TDA** で、Betti 数や persistent homology を用いて接続性・穴・トンネルを特徴化する系譜。第四に、**セグメンテーション＋トポロジー制約**で、TopoLoss や clDice のように、IoU や Dice だけでは拾えない broken connection を抑える方向。第五に、**CNN/Transformer/GNN/ハイブリッド学習器**であり、特に U-Net、ViT/Swin、GNN、学習＋厳密パス探索の併用が有力候補になる。 [2]

合成データについては、ユーザー提案の「**二点選択→ランダム点追加または周囲円周拡大で接続を試み、接続成立を正例・未成立を負例**」は、研究用として非常に良い出発点である。これを厳密化するなら、連結性ラベルを**人手ではなくオラクル**で付与し、4 近傍か 8 近傍かを明示し、さらに**正負の反事実ペア**を作って「一本の橋を消しただけでラベル反転する」近接サンプルを大量に含めるべきである。こうすると、単なる面積・濃度・局所テクスチャのショートカットでは解けず、「本当に繋がっているか」を学習器に要求できる。 [3]

本レポートの最終提案は、**主系列の推奨生成アルゴリズムとして「制御付きブリッジ成長法」**を採用し、評価では **分類指標（Accuracy, F1, ROC-AUC）** と **トポロジー指標（clDice, Betti 誤差, connected-component consistency, 必要なら APLS）** を併用し、モデル比較は **End-to-end CNN / U-Net 系 / ViT 系 / Skeleton-GNN / TDA 特徴 / パス探索＋学習ハイブリッド** の六系統で行う、というものである。実験は ID テストだけでなく、**未観測パラメータ組合せの OOD テスト**、**難易度別テスト**、**反事実ペアテスト**、**実在しにくいが論理的には妥当な adversarial 合成画像テスト**を分けて行うのが望ましい。合成データはエッジケース生成に強い一方、ドメインギャップやバイアスの問題があるため、**「主タスク評価」と「ストレステスト評価」を分離する設計**が最も堅い。 [4]

課題設定と研究背景

この問題は、画像領域を $\Omega \subset \mathbb{Z}^2$、前景二値画像を $F : \Omega \to \{0, 1\}$、注目点を $p, q \in \Omega$ としたとき、**指定した近傍系** $\kappa \in \{4, 8\}$ のもとで p と q が同じ connected component に属するかを判定する問題として書ける。グラフ的には、前景画素を頂点、隣接前景画素を辺とする無向グラフ G_F を作り、$y = \mathbf{1}[q \in CC_\kappa(p)]$

をラベルとする。connected component は「任意の二頂点間にパスが存在する最大部分グラフ」であり、画像処理側では SciPy や scikit-image の連結成分ラベリングにより厳密に計算できる。 [5]

この設定が難しい理由は、第一に**長距離依存性**である。二点間の局所近傍だけを見てもラベルは決まらず、ときには画像全体を横断して「一本の細いパス」を追跡する必要がある。Pathfinder はまさに「二つの円が同じ破線パスで繋がっているか」を問う視覚推論課題として提案され、Long Range Arena は Pathfinder と Pathfinder-X を長距離文脈モデリングの試験場として採用した。LRA の説明でも、こうした synthetic image タスクは**構造的・視空間的推論**を要求する長文脈ベンチマークの一部として位置づけられている。 [6]

第二に**細幅領域と高曲率**である。トポロジー保存型セグメンテーション研究では、細い構造では「1 ピクセルの欠損」がただちに接続性破綻につながることが繰り返し問題視されている。clDice はチューブ状構造の連結性保存を狙った指標・損失として導入され、TopoLoss は broken connections のような微細トポロジー誤りを直接抑制する。つまり、この課題は通常の分類問題というより、**細線構造上のトポロジー判定**に近い。 [7]

第三に、**CNN の局所性バイアスとその限界**である。Kim らは Pathfinder などの知覚グルーピング課題で、難易度上昇により bottom-up のみのネットワークが学習しにくくなり、horizontal / top-down 接続が有利になると報告した。一方で Lüddecke と Ecker は、適切に設計した narrow ResNet が Pathfinder と cABC を高精度に解けると示し、再帰が必須とは限らないと主張した。さらに近年には、LRA の一部タスクが真の長距離依存だけでなく locality bias の影響も受けうるという批判もある。したがって本研究では、**「モデルの限界そのもの」より「どの条件で失敗しやすいか」を定量化する評価設計**が重要になる。 [8]

既存研究の整理

日本語で押さえやすい入口

日本語で概観するなら、まず TDA については J-STAGE の解説「トポロジカルデータ解析の基礎と医療応用」が、persistent homology の基本と医用画像との関係を短く整理している。TDA を画像セグメンテーションに直接使う日本語論文としては「位相的データ解析に基づく濃淡画像のセグメンテーション」があり、画像内の対象を “穴” として捉える発想が本課題の topology-aware 設計に近い。細線化では Hilditch の連結性保存条件の誤用を指摘する論文があり、**細線化は便利だが実装の細部を誤ると接続性評価そのものが壊れる**という注意点が得られる。深層学習によるセグメンテーションの概説としては、電子顕微鏡画像の日本語レビューが、手作業限界と DL 導入の背景を整理している。 [9]

種別	日本語ソース	本課題への効用
TDA 概説	「トポロジカルデータ解析の基礎と医療応用」J-STAGE [10]	Betti 数・persistent homology の基礎理解
TDA 応用	「位相的データ解析に基づく濃淡画像のセグメンテーション」J-STAGE [11]	画像をトポロジー特徴で切る発想の具体例
細線化	「Hilditch細線化アルゴリズムにおける連結性保存条件の誤用について」J-STAGE [12]	スケルトン抽出時の連結性破壊リスク
DL セグメンテーション概説	「Deep learningを用いた生物電子顕微鏡画像のセグメンテーション」J-STAGE [13]	セグメンテーション設計・教師データ課題の導入
Vision Transformer 周辺	J-STAGE の ViT 関連解説・書評論文群 [14]	ViT 系モデルの日本語導入

主要な研究系譜

グラフ連結性の観点では、NetworkX の connected_components は「無向グラフの connected components がノード集合を互いに素な連結部分に分割する」と定義しており、本課題のラベルオラクルにそのまま使える。画像内パス探索については scikit-image が pixel graph と shortest path を公式に提供しており、厳密判定器または post-processing として有用である。 15

形態学的手法では、OpenCV は erosion / dilation / opening / closing を**形状に基づく二値画像操作**として整理している。連結判定タスクでは、こうした演算はノイズ除去やギャップ閉塞に役立つが、カーネルが大きすぎると偽の接続を作る。細線化については scikit-image が「binary object を 1-pixel wide representation に還元し、topology の表現や特徴抽出に有用」と明記しており、接続性オラクルやグラフ化の前処理として極めて自然である。 16

TDA 系では、GUDHI が persistent homology 計算と persistence diagram のベクトル化を、giotto-tda が scikit-learn ライクな topological machine learning ツール群を提供している。persistent homology は higher-order connectivity を含む multi-scale topology を要約でき、GUDHI の representation module や giotto-tda の PersistenceImage を使うと、Betti 曲線や persistence image を分類器入力に落とし込める。日本語文献でも、TDA が画像の本質的な形を捉えるための道具として位置づけられている。 17

セグメンテーションとトポロジー保存の文脈では、Hu らの TopoLoss は「正解と同じ Betti 数を持つように学習する differentiable loss」を提案し、Betti number error を直接下げることを示した。Shit らの clDice はスケルトンとマスクの交差に基づく connectivity-aware 指標で、2D/3D の binary segmentation について homotopy equivalence の範囲でトポロジー保存を保証すると述べている。Boundary IoU は Mask IoU より境界誤差に敏感で、Hausdorff distance は境界の空間的不一致をより強く捉える。つまり、**IoU 単独ではこの課題の品質を取り違える**可能性が高い。 18

学習モデルの系譜では、U-Net が文脈取得と精密局在を両立する古典的基盤として依然有力であり、ViT は full-image token interaction により global context を扱える。Swin Transformer は shifted windows によって window 間接続を持つ階層型 Transformer として、セグメンテーション用途でも広く使われている。また、Pathfinder 系では知覚グルーピング課題として水平結合やトップダウン結合の有効性が報告された一方、適切な CNN 基盤でも高難度版を解けるとする反証もあるため、**単一アーキテクチャへの賭けではなく、複数系列を比較する実験設計**が必要である。 19

道路や血管のような network-like structure の研究は、二点連結判定の近縁分野として重要である。DeepRoadMapper は CNN で道路領域をセグメントし、その後 thinning によって road centerline グラフを抽出する。Batra らは segmentation が connected roads を落としやすく、shortest path による後処理で接続性を改善できると報告した。SpaceNet 系では APLS が提案グラフと正解グラフの最短経路長差を集計する connectivity-oriented metric として用いられている。これらは本課題で**「画素分類」と「接続性評価」を分離する設計**の参考になる。 20

主要論文・実装・ベンチマーク

領域	代表論文・実装・ベンチマーク	位置づけ
二点連結ベンチマーク	Pathfinder / cABC を導入した Kim らの ICLR 論文、LRA の Pathfinder / Pathfinder-X 21	本課題に最も近い公開標準
CNN vs recurrence	Lüddecke & Ecker「CNNs Efficiently Learn Long-Range Dependencies」および公開実装 22	CNN の反証的強ベースライン

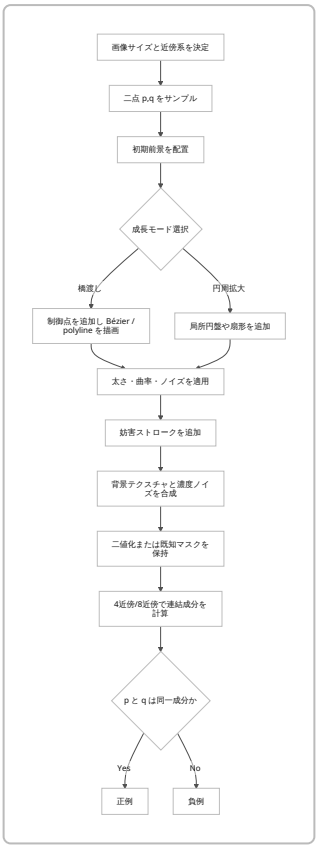
領域	代表論文・実装・ベンチマーク	位置づけ
セグメンテーション基盤	U-Net 論文と公開実装 [23]	細線構造のマスク推定基盤
Transformer 基盤	ViT、Swin、Swin segmentation 実装 [24]	長距離依存の代表比較対象
トポロジー損失	TopoLoss、clDice と実装 [25]	接続性を直接扱うための本命
スケルトン・形態学	scikit-image skeletonize、OpenCV morphology、Hilditch 論文 [26]	オラクル・後処理・説明性
グラフ評価	APLS 実装、DeepRoadMapper、SpaceNet 系 [27]	接続品質の補助評価
TDA ライブラリ	GUDHI、giotto-tda、scikit-tda / persim [28]	トポロジー特徴抽出・分類

合成データ生成法の形式化

推奨生成方針

ユーザー提案を形式化すると、最も扱いやすいのは**制御付きブリッジ成長法**である。これは、二点 p, q を先に打ち、そこから前景成分を「橋渡し」しようとする局所操作を繰り返して最終画像を合成し、最後にオラクルで連結性を判定する方法である。重要なのは、ラベルを「生成意図」ではなく**最終二値画像の厳密連結性**で決める点である。これにより、アンチエイリアスや細幅化で意図しない断線・接続が起きても、ラベルの一貫性を保てる。connected-component labeling や pixel graph 上の path existence は既存ライブラリで厳密実装できる。 [29]

以下の Mermaid 図は推奨生成フローである。



数学的定式化

提案生成器 $\mathcal{G}$ を、潜在パラメータ θ と乱数 ξ から画像 I、前景マスク F、ラベル y を返す確率過程として定義する。

$$(I, F, y) = \mathcal{G}(\theta, \xi), \qquad y = \mathbf{1}[q \in CC_\kappa(p; F)].$$

ここで θ は少なくとも、画像解像度 R、初期二点距離 d_0、追加点数 N、円直径分布 (μ_r, σ_r)、曲率制御 κ_c、線幅 w、妨害曲線本数 m、ノイズ強度 σ_n、背景テクスチャ複雑度 t_b、および連結判定近傍系 κ を含む。Bézier でも polyline でもよいが、**中心線** $C(s)$ を先に作り、そこに半径関数 $r(s)$ を持つ Minkowski 和で太さを与えると、細幅区間や太さの非一様性を制御しやすい。スケルトン化研究や clDice の文脈でも、中心線と太さの分離は自然な表現である。 30

推奨パラメーター一覧

パラメータ	記号	推奨値の例	難易度への主効果	コメント
解像度	R	128, 256, 512	低解像度ほど難化	1–2 px のギャップが致命的になりやすい
初期点間距離	d_0	0.15–0.75 画面対角	距離↑で難化	長距離依存性を直接増やす
追加点数	N	Poisson / NegBin	多すぎると複雑化	同時に連結成立確率も変える
円直径平均	μ_r	3–25 px	小さいほど難化	細線化・断線に敏感

パラメータ	記号	推奨値の例	難易度への主効果	コメント
円直径分散	σ_r	0–8 px	分散↑で局所難化	幅のムラを導入
曲率制御	κ_c	低・中・高の三水準	高曲率で難化	追跡が局所的に曖昧になる
最小線幅	$w_{\min}$	1–4 px	小さいほど難化	topology break を起こしやすい
妨害ストローク数	m	0–50	多いほど難化	Pathfinder 的難しさの主因
背景テクスチャ複雑度	t_b	平坦〜低周波/高周波混合	高いほど難化	shortcut 抑制にも効く
強度ノイズ	σ_n	0–0.2	高いほど難化	binarization 依存を増やす
アンチエイリアス係数	a	1, 2, 4	中庸が望ましい	ラベルオラクルと整合必須
近傍系	κ	4 or 8	8 の方が易しい場合多い	4/8 でラベルが変わりうる [31]

正例・負例の作り方

通常の rejection sampling だけでも正負は作れるが、研究上は**反事実ペア生成**が特に重要である。正例を一つ作った後、そのスケルトングラフの**bridge edge** を一つ除去して負例を作れば、正負は局所統計量がほぼ同じまま連結性だけが反転する。これにより、面積・平均濃度・曲線本数のような shortcut feature を極力無効化できる。道路ネットワーク研究でも、graph 抽出後の shortest path や path similarity を評価軸に置く発想が採られており、本課題でも「一本の橋の有無」が中核情報であることをデータ側で保証するのが有利である。 [32]

代替生成法との比較

生成法	概要	利点	欠点	本課題への適合
制御付きブリッジ成長法	二点から橋渡し操作を繰り返す	ユーザー案を自然に拡張でき、反事実負例が作りやすい	パラメータ空間が広い	**最有力**
Pathfinder 型破線 snake	既存の snake 生成器で破線経路を描く	既存文献との比較が容易、公開実装あり [33]	破線という見た目に偏る	**強ベースライン**
グラフ先行生成＋ラスタライズ	潜在グラフを作り線画化	連結性を理論上厳密に制御しやすい	画像として単調になりやすい	ベンチマーク補助向き
ランダムウォーク / self-avoiding walk	経路を逐次的に成長	長距離・蛇行を作りやすい	太さ制御や hard negative がやや弱い	補助候補

生成法	概要	利点	欠点	本課題への適合
円盤/扇形拡大型	ユーザー案の円周拡大を主に使う	太さや細幅ボトルネックを作りやすい	中心線の意味が薄れやすい	モルフォロジー寄り難例生成に有効
L-system / 文法生成	分岐や再帰構造を生成	階層構造の OOD テストに有効	実装がやや重い	枝分かれ難例向き

推奨擬似コード

```
def generate_sample(cfg, rng):
    H, W = cfg.resolution
    kappa = cfg.connectivity   # 4 or 8

    # 1) 点のサンプリング
    p, q = sample_point_pair(H, W, dist_range=cfg.dist_range, rng=rng)

    # 2) 初期前景
    mask = empty_binary(H, W)
    draw_disk(mask, p, radius=cfg.marker_radius)
    draw_disk(mask, q, radius=cfg.marker_radius)

    # 3) ターゲット前景の成長
    state = init_growth_state(p, q, rng)
    for _ in range(sample_num_steps(cfg, rng)):
        if rng.rand() < cfg.bridge_prob:
            ctrl = sample_bridge_control_point(state, cfg, rng)
            curve = make_curve(state, ctrl, curvature=sample_curvature(cfg, rng))
            width = sample_width(cfg, rng)
            rasterize_tube(mask, curve, width=width)
            update_state(state, curve)
        else:
            center = sample_growth_center(state, rng)
            radius = sample_radius(cfg, rng)
            sector = sample_sector(center, radius, cfg, rng)
            rasterize_region(mask, sector)
            update_state(state, sector)

    # 4) 妨害ストローク
    for _ in range(sample_distractor_count(cfg, rng)):
        distractor = sample_distractor(cfg, rng)
        rasterize_shape(mask, distractor)

    # 5) 背景・ノイズ・濃淡
    image = render_intensity(mask, cfg, rng)
    image = add_background_texture(image, cfg, rng)
    image = add_noise(image, cfg, rng)

    # 6) 厳密ラベル
```

```
    cc = connected_components(mask, connectivity=kappa)
    y = int(same_component(cc, p, q))

    # 7) 反事実負例の任意生成
    if cfg.enable_counterfactual and y == 1 and rng.rand() < cfg.cf_prob:
        critical_edge = find_bridge_on_skeleton(mask, p, q)
        if critical_edge is not None:
            mask_cf = remove_small_segment(mask, critical_edge, cfg)
            image_cf = render_intensity(mask_cf, cfg, rng)
            y_cf = int(same_component(connected_components(mask_cf, kappa), p, q))
            return [(image, mask, y), (image_cf, mask_cf, y_cf)]

    return [(image, mask, y)]
```

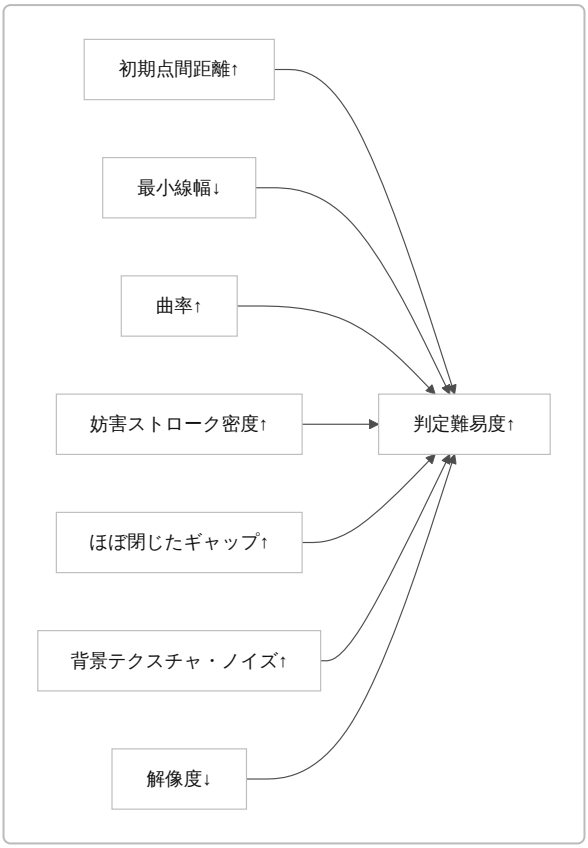
この設計の核は、**見た目の生成とラベル判定を分離し、最後に厳密オラクルで再ラベルすること**、そして**counterfactual negative を強制的に混ぜること** である。Pathfinder の公開生成器や LRA の builder は比較対象として流用しやすいが、ユーザー案の方が太さ・曲率・背景の独立制御に優れるため、研究用データセットの主系列としてはこちらを推奨する。[34]

難易度設計と評価指標

難易度に直結するパラメータ仮説

連結判定の難易度を最も強く左右するのは、**初期点間距離、最小線幅、高曲率、妨害密度、ほぼ接している非連結部位、そして背景テクスチャ**だと予想される。Pathfinder 系研究は長距離・クラッタ増加で課題が難しくなることを前提に設計されており、トポロジー保存型セグメンテーション研究は細い構造で broken connection が増えることを繰り返し報告している。したがって、難易度を単一の「easy / hard」で済ませず、少なくとも **distance / width / curvature / clutter / texture** の多軸で評価するのが適切である。[35]

下図は、推奨する「パラメータ→難易度」概念図である。



検証方法

検証は、単純な平均精度比較ではなく、**難易度応答曲線**として出すのが良い。具体的には、各サンプルに潜在パラメータを保存し、(i) 一変量スイープ、(ii) 二因子相互作用のグリッド、(iii) Latin hypercube あるいはランダム計画による広域サンプリング、の三段で調べる。モデル誤りを従属変数として、距離・線幅・曲率・クラッタ等を説明変数に持つロジスティック回帰や非線形回帰を当てれば、「どの条件が効いているか」を可視化できる。これは提案設計だが、LRA 系の difficulty-controlled benchmark と topology-aware segmentation の評価思想を合わせた形になっている。 36

データに存在しない画像を許容するか

結論から言うと、**主テストでは限定的に、ストレステストでは積極的に許容**するのがよい。合成データは「現実では稀な edge case を大量に作れる」点が最大の利点である一方、synthetic-to-real の domain gap や生成バイアス、一般化可能性の問題がある。したがって、訓練・主評価は「論理的かつある程度自然な画像」に寄せ、別枠で **adversarial synthetic split** を作って、非自然だが連結判定ロジックを強く試す画像を置く構成が最も分析しやすい。 37

実務上は、データセット全体を次の三層に分けるのが扱いやすい。第一層は**自然寄り合成**で、道路・血管・配線に似た細線構造。第二層は**抽象妥当合成**で、自然画像では珍しいが論理的には問題ないパターン。第三層は**ストレステスト合成**で、極端な曲率・極細ボトルネック・ほぼ接触・局所的に矛盾した陰影などを持つ。結果表ではこの三層を分けて示すべきである。これは synthetic data の利点と限界を切り分けるための提案である。 37

ラベル曖昧性と合意形成

純合成コアセットでは、ラベルは人手ではなく**オラクル**で与えるため、原理的には曖昧性を排除できる。ただし、実際には「点が前景境界に乗る」「アンチエイリアス後の閾値で連結性が変わる」「4 近傍と 8 近傍で

結果が反転する」といった実装曖昧性が残る。したがって、ラベル仕様書には **近傍系、二値化法、点の包含規則** を明記し、それが変わるとラベルも変わりうることを公開する必要がある。SciPy の label と scikit-image の connectivity/Euler number 関連説明は、こうした近傍系依存性を明確に示している。 [31]

もし人手アノテーションを併用するなら、三つの方法がある。第一に複数アノテータ投票、第二に STAPLE による確率的真値推定、第三に disagreement をそのまま soft label にする方法である。STAPLE は複数セグメンテーションから EM により probabilistic true segmentation を推定する古典手法で、近年の soft-label 研究では annotator confidence や disagreement を保持した方が性能や calibration に利点があると報告されている。本課題でも、曖昧画像だけ人手評価し、それを確率ラベルとして学習器校正に使う設計は理にかなう。 [38]

推奨評価指標

本課題の主タスクは二値分類なので、Accuracy, F1, ROC-AUC は必須である。F1 は precision と recall の調和平均として定義され、ROC-AUC はスコア順位に基づくしきい値非依存評価を与える。クラス不均衡や hard negative の増加を考えると、Accuracy 単独より F1 と ROC-AUC の併記が望ましい。 [39]

ただし、もし中間表現としてマスクやスケルトンを出力するなら、**IoU / Dice だけでは不十分**である。Boundary IoU は標準 IoU より境界誤差に敏感で、Hausdorff distance は空間的不一致をより厳しく捉える。さらに topology-aware な観点では clDice、Betti number error、connected component count error、必要に応じて skeleton graph に対する APLS を報告すべきである。特に clDice と Betti 誤差は「繋がっているべき細線構造が切れた」ケースに強い。 [40]

指標群	指標	何を見るか	本課題での重要度
分類	Accuracy	全体正答率	中
分類	F1	hard negative 下のバランス性能	高 [41]
分類	ROC-AUC	しきい値非依存の識別力	高 [42]
マスク	IoU / Dice	領域重なり	中
境界	Boundary IoU	境界品質	高 [43]
境界	Hausdorff	最悪境界ずれ	高 [44]
トポロジー	clDice	スケルトン中心の接続性	非常に高 [45]
トポロジー	Betti 誤差	連結成分数や穴の差	非常に高 [46]
グラフ	APLS	パス品質・経路長整合	補助的に有用 [47]
ペア単位	点対連結一貫性	二点判定そのもの	主指標

判定モデル候補と長距離依存性対策

モデルは、**直接分類器**、**セグメンテーション系**、**グラフ系**、**TDA 系**、**ハイブリッド系**に分けて比較するのが自然である。入力は、元画像に加えて二点を別チャネルで与えるのがよい。これは本質的に conditioned connectivity query であり、二点情報を明示しないと、モデルは「画像全体の連結性」と「指定二点の連結性」を混同しやすい。Pathfinder 系も実質的には指定点つきの relation task として解かれている。 [48]

モデル族	代表	利点	欠点	長距離対策	推奨役割
CNN 直接分類	ResNet / narrow ResNet	実装容易、高速、Pathfinder 系で強ベースライン [22]	rationale が見えにくい、細線 topology を暗黙学習に委ねる	dilated conv, multi-scale, 大きめ受容野 [49]	**必須ベースライン**
U-Net 系	U-Net / nnU-Net	マスク出力でき、失敗解析しやすい [50]	最終連結判定には閾値と後処理が必要	skip connection, multi-scale, topology loss	**本命その一**
ViT 系	ViT / Swin	global context を扱いやすい、長距離依存に強い設計 [51]	計算量が高い、少量データでは不安定	self-attention, shifted windows	比較上重要
GNN 系	skeleton graph + GNN	連結性そのものをグラフで扱える [52]	前処理品質に依存、グラフ化が難しい	message passing, shortest-path-aware features	**本命その二**
TDA 系	persistence image + SVM/MLP	topology への明示的感度 [53]	局所幾何や query-specific 情報を扱いにくい	persistent homology の多尺度性	解析ベースライン
ハイブリッド	U-Net + skeleton + path search / graph search	説明性・厳密さ・精度のバランスがよい [54]	実装がやや複雑	学習で候補生成、探索で厳密判定	**最有力運用案**

CNN 系については、「長距離依存が苦手」という見方と「適切設計なら解ける」という見方の両方を尊重すべきである。したがって本研究では、単純 ResNet と dilated / multi-scale 版を分けて評価し、**どの設計変更がどの難易度軸に効くか**を比較するのがよい。dilated convolution は解像度を保ったまま受容野を拡大する古典手法であり、近年も semantic segmentation において重要性が続いている。 [55]

U-Net 系は、二点連結を**セグメンテーション問題に還元**したい場合に最も扱いやすい。具体的には、入力を「画像 + 点ヒートマップ 2 枚」にし、出力を「二点を結ぶべき target structure mask」にすると、最終判定は connected component または shortest path の厳密判定に落とせる。ここに clDice や TopoLoss を入れると、IoU だけでは失う細線接続を補強できる。nnU-Net はデータ依存でパイプラインを自動調整するため、強い U-Net 基準線として有用である。 [56]

ViT/Swin 系は、画像全域の token interaction により長距離依存を扱いやすい。特に Swin は計算量を抑えつつ cross-window connection を持ち、dense prediction でも広く用いられている。他方、データが完全に合成であり query も明示的な本課題では、ViT が必ずしも CNN を上回るとは限らない。ここは empirical question なので、**分類型・セグメント型の双方で評価**すべきである。 [57]

GNN は、予測マスクやスケルトンから得たグラフ上で二点連結を判定するため、問題構造との相性が非常によい。難点は、スケルトン化やノード抽出が不安定だと誤差が増幅することであるが、逆に言えば失敗要因が追いやすい。TDA 系は単独最強モデルになる可能性は高くないが、**「モデルは何を topology として拾えているか」**を調べる解析基準として価値が高い。GUDHI や giotto-tda は persistence diagram の機械学習表現をそのまま提供する。 [58]

最終的な推奨順位は、研究用比較としては **U-Net + topology loss + exact graph判定**、**narrow ResNet 系の直接分類**、**ViT/Swin 系**、**Skeleton-GNN**、**TDA 特徴分類器** の順に並べるのがよい。運用上の第一候補は、説明性と再現性の観点から **「学習で候補マスクを出し、最後は厳密 connectivity oracle で判断するハイブリッド」** である。これは道路抽出研究の成功パターンとも整合的である。 [59]

実験プロトコルと分析計画

データセット規模と分割

合成データは追加コストが低いため、まずは**パイロット 5 万枚**、本実験では**学習 20 万、検証 2 万、ID テスト 2 万、OOD テスト 2 万、反事実テスト 2 万**程度を推奨する。これは既存の合成 reasoning benchmark が比較的大規模運用されていることと、Pathfinder 系がデータ量に敏感であることを踏まえた実務的提案である。分割では、画像 seed だけでなく**潜在パラメータの組合せ**でリークを防ぐ必要がある。たとえば train に存在しない「高曲率 × 極細 × 高クラッタ」を OOD テストへ回す。 [21]

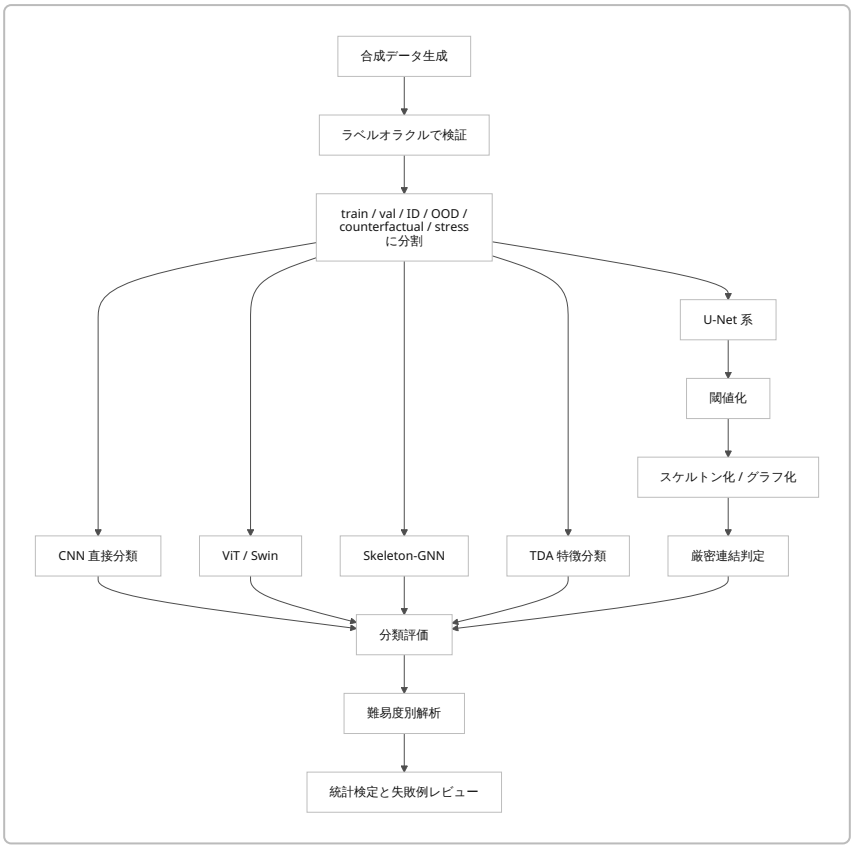
推奨する分割設計は、(i) ID: パラメータ分布一致、(ii) Interpolation OOD: 値域内だが未観測組合せ、(iii) Extrapolation OOD: 訓練外レンジ、(iv) Counterfactual: 一本の橋だけ違う対ペア、(v) Adversarial synthetic: 非自然だが論理的に難しい画像、の五分割である。LRA / Pathfinder に対する locality bias の議論もあるため、**単一ベンチマーク点数だけで「長距離依存を解いた」と言わない**設計が重要である。 [60]

評価と可視化

分類評価は Accuracy, F1, ROC-AUC を基本とし、閾値 0.5 固定だけでなく ROC 全体も見る。セグメンテーションを経由する場合は IoU, Dice, Boundary IoU, Hausdorff, clDice, Betti 誤差を併記する。さらに本課題固有指標として、**点対連結一貫性**と**スケルトングラフ上の shortest-path consistency** を出すのがよい。グラフ抽出タスクとの比較可能性を求める場合のみ APLS を補助的に採用する。 [61]

可視化は、単なる「正解/不正解」一覧よりも、**失敗原因に対応する可視化**を出すべきである。最低限、入力画像、二点位置、予測スコア、予測マスク、スケルトン、 connected component 色分け、誤った shortest path、そして ground truth との差分を並べる。道路抽出や topology-aware segmentation の実装では、マスク→スケルトン→グラフの流れが一般的であり、本課題でもその流れは失敗解析に極めて有効である。 [62]

以下は推奨実験パイプラインである。



統計的検定

同一テストセット上の二分類器比較には McNemar 検定が適している。複数 seed にわたるスコアの比較には Wilcoxon signed-rank test が使いやすい。ROC-AUC の信頼区間やモデル差の比較は bootstrap か DeLong 系実装で補える。こうした統計処理は deep learning 実験でも、単一 seed の偶然差を避けるために必須である。 63

推奨実験表

項目	推奨設定
乱数 seed	少なくとも 5 seed
学習データ	20 万枚前後を主実験、5 万枚を pilot
入力	画像 + 二点ヒートマップ 2 ch
主ベースライン	narrow ResNet、U-Net、nnU-Net、ViT/Swin、Skeleton-GNN、TDA 特徴器
損失	BCE / CE、Dice、clDice、TopoLoss の比較
主評価	Accuracy, F1, ROC-AUC
補助評価	IoU, Boundary IoU, Hausdorff, clDice, Betti 誤差, APLS
分析軸	距離、線幅、曲率、クラッタ、背景、解像度、近傍系
統計	McNemar、Wilcoxon、ROC-AUC CI
可視化	正例/負例例示、失敗例、予測マスク、スケルトン、難易度曲線

実装上の注意点とリスク

最大のリスクは**ラベルノイズではなく「仕様ノイズ」**である。どの近傍系を連結とみなすか、アンチエイリアス後にどう閾値化するか、点が境界上にあるとき前景に含むか、という仕様差だけでラベルは変わる。distance-based metric にも実装差異があり得ることが近年指摘されており、Hausdorff や topology 指標も「どの実装を使ったか」を固定しないとベンチマークが揺れる。したがって、**データ生成コード・ラベルコード・評価コードを一体で公開**するのが必須である。 64

第二のリスクは計算コストである。global self-attention は高解像度では重く、persistent homology も大規模 2D/3D では計算が高価になる。スケルトングラフ化も前処理としては軽くない。したがって、まず軽量 CNN と U-Net 系で difficulty curve を把握し、その後に ViT や TDA 系を投入する段階的設計が現実的である。MMSegmentation、nnU-Net、MONAI、PyG はそれぞれ成熟した実装基盤を提供しているため、ゼロから書くよりこれらを流用した方がよい。 65

第三は再現性である。Pathfinder や topology-aware 学習では、データ生成器の細部が結果に強く効く。したがって、乱数 seed、ライブラリバージョン、補間・レンダリング法、閾値、スケルトン化アルゴリズム、グラフ抽出規則を固定し、可能なら生成済み metadata を保存すべきである。Hilditch 細線化の日本語論文が示すように、実装の取り違えは「本来保存されるべき連結性」を簡単に壊す。 66

倫理面では、主な論点は個人情報ではなく**評価の誤誘導**である。合成データは edge case を作るに優れるが、 domain gap や synthetic bias によって「この問題は解けるが実データでは効かない」モデルを過大評価しがちである。そのため、合成主タスクで得た結論は「論理構造推論能力」に関するものとして限定し、可能なら小規模実データに近い補助セットで外部妥当性を確認すべきである。 37

参考文献と推奨実装

推奨する実装スタック

目的	推奨ライブラリ / 実装	理由
画像生成・形態学	OpenCV, scikit-image morphology / skeletonize 67	形態学・細線化が安定している
連結判定	SciPy `ndimage.label`, NetworkX `connected_components` 68	ラベルオラクルが明確
画像上の経路探索	scikit-image graph / shortest path 69	path-based oracle と可視化向き
TDA	GUDHI, giotto-tda, scikit-tda/persim 28	persistent homology と vectorization が揃う
セグメンテーション基盤	nnU-Net, MMSegmentation, MONAI 70	再現性ある比較がしやすい
GNN	PyTorch Geometric 71	skeleton graph 学習に適する
Transformer 実装	Hugging Face Transformers, Swin official repo 72	ViT/Swin 比較が容易
トポロジー損失	TopoLoss, clDice 公式実装 73	topology-aware baseline をすぐ作れる

目的	推奨ライブラリ / 実装	理由
既存 benchmark	drewlinsley/pathfinder, google-research/long-range-arena [33]	Pathfinder 互換比較が可能

主要参考文献リスト

分類	文献・資料
中核ベンチマーク	Kim et al., Disentangling neural mechanisms for perceptual grouping（Pathfinder/cABC） [74]
中核ベンチマーク	Tay et al., Long Range Arena（Pathfinder / Pathfinder-X を含む） [75]
CNN 比較	Lüddecke & Ecker, CNNs Efficiently Learn Long-Range Dependencies [76]
セグメンテーション基盤	Ronneberger et al., U-Net [77]
Transformer 基盤	Dosovitskiy et al., ViT、Liu et al., Swin Transformer [78]
トポロジー損失	Hu et al., Topology-Preserving Deep Image Segmentation [46]
トポロジー指標	Shit et al., clDice [45]
道路トポロジー	Mattyus et al., DeepRoadMapper、Batra et al., road connectivity 改善 [79]
TDA 概説	GUDHI / giotto-tda / 日本語 J-STAGE 解説群 [80]
評価指標	Boundary IoU、Hausdorff、APLS、F1、ROC-AUC の公式資料 [81]

最終提案

本研究テーマに対して最も筋の良い出力物は、**制御付きブリッジ成長法で合成したデータセット**、**U-Net + clDice/TopoLoss + 厳密 connectivity oracle** を主モデルに置いた実験プロトコル、そして **narrow ResNet / ViT-Swin / Skeleton-GNN / TDA 特徴器** を比較対象とする設計である。評価は F1 と ROC-AUC を主にしつつ、clDice と Betti 誤差で topology を監査し、結果は距離・曲率・線幅・クラッタで分解して読むべきである。これにより、「モデルが高精度だった」だけでなく、「**どの種類の連結性で、なぜ失敗するのか**」まで言える研究になる。 [82]

---

[1] [6] [8] [21] [35] [48] [74] Disentangling neural mechanisms for perceptual grouping
https://openreview.net/forum?id=HJxrVA4FDS&utm_source=chatgpt.com

[2] [5] [15] connected_components — NetworkX 3.6.1 documentation
https://networkx.org/documentation/stable/reference/algorithms/generated/networkx.algorithms.components.connected_components.html?utm_source=chatgpt.com

[3] [29] [68] label — SciPy v1.18.0 Manual
https://docs.scipy.org/doc/scipy/reference/generated/scipy.ndimage.label.html?utm_source=chatgpt.com

[4] [39] [41] [61] [82] f1_score — scikit-learn 1.9.0 documentation
https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html?utm_source=chatgpt.com

[7] [45] [2003.07311] clDice -- A Novel Topology-Preserving Loss ...
https://arxiv.org/abs/2003.07311?utm_source=chatgpt.com

9 10 トポロジカルデータ解析の基礎と医療応用 - J-STAGE
https://www.jstage.jst.go.jp/article/mit/38/1/38_27/_article/-char/ja?utm_source=chatgpt.com

11 位相的データ解析に基づく濃淡画像のセグメンテーション - J-STAGE
https://www.jstage.jst.go.jp/article/iscie/34/9/34_243/_article/-char/ja/?utm_source=chatgpt.com

12 66 Hilditch細線化アルゴリズムにおける連結性保存条件の誤用に ...
https://www.jstage.jst.go.jp/article/iieej/39/4/39_4_490/_article/-char/ja/?utm_source=chatgpt.com

13 Deep learningを用いた生物電子顕微鏡画像のセグメンテーション
https://www.jstage.jst.go.jp/article/kenbikyo/58/1/58_31/_article/-char/ja/?utm_source=chatgpt.com

14 Vision Transformer 入門 ― 新しいコンピュータビジョンの世界 ...
https://www.jstage.jst.go.jp/article/isciesci/68/7/68_284/_article/-char/ja?utm_source=chatgpt.com

16 67 OpenCV: Morphological Transformations
https://docs.opencv.org/3.4.20/d4/d76/tutorial_js_morphological_ops.html?utm_source=chatgpt.com

17 28 80 GUDHI library – Topological data analysis and geometric ...
https://gudhi.inria.fr/?utm_source=chatgpt.com

18 25 46 Topology-Preserving Deep Image Segmentation - NeurIPS
https://proceedings.neurips.cc/paper/2019/hash/2d95666e2649fcfc6e3af75e09f5adb9-Abstract.html?utm_source=chatgpt.com

19 23 50 56 77 [1505.04597] U-Net: Convolutional Networks for Biomedical ...
https://arxiv.org/abs/1505.04597?utm_source=chatgpt.com

20 54 59 62 79 DeepRoadMapper: Extracting Road Topology from Aerial Images
https://openaccess.thecvf.com/content_ICCV_2017/papers/Mattyus_DeepRoadMapper_Extracting_Road_ICCV_2017_paper.pdf?utm_source=chatgpt.com

22 55 76 CNNs efficiently learn long-range dependenci - OpenReview
https://openreview.net/pdf?id=dPwyQnHUVvw&utm_source=chatgpt.com

24 51 57 78 An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale
https://arxiv.org/abs/2010.11929?utm_source=chatgpt.com

26 30 58 Skeletonize — skimage 0.26.0 documentation
https://scikit-image.org/docs/stable/auto_examples/edges/plot_skeleton.html?utm_source=chatgpt.com

27 32 47 GitHub - CosmiQ/apls: Python code to evaluate the APLS metric
https://github.com/CosmiQ/apls?utm_source=chatgpt.com

31 64 scipy.ndimage.label — SciPy v1.9.1 Manual
https://docs.scipy.org/doc//scipy-1.9.1/reference/generated/scipy.ndimage.label.html?utm_source=chatgpt.com

33 34 GitHub - drewlinsley/pathfinder
https://github.com/drewlinsley/pathfinder?utm_source=chatgpt.com

36 75 Long Range Arena: A Benchmark for Efficient Transformers
https://arxiv.org/abs/2011.04006?utm_source=chatgpt.com

37 Synthetic Data for Computer Vision @ CVPR 2026
https://syndata4cv.github.io/?utm_source=chatgpt.com

38 Simultaneous truth and performance level estimation (STAPLE ...
https://ieeexplore.ieee.org/document/1309714?utm_source=chatgpt.com

40 43 81 Boundary IoU: Improving Object-Centric Image Segmentation ...
https://openaccess.thecvf.com/content/CVPR2021/papers/Cheng_Boundary_IoU_Improving_Object-Centric_Image_Segmentation_Evaluation_CVPR_2021_paper.pdf?utm_source=chatgpt.com

42 roc_auc_score — scikit-learn 1.9.0 documentation
https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html?utm_source=chatgpt.com

44 monai.metrics.hausdorff_distance — MONAI 1.3.0 ...
https://monai.readthedocs.io/en/1.3.0/_modules/monai/metrics/hausdorff_distance.html?utm_source=chatgpt.com

49 Multi-Scale Context Aggregation by Dilated Convolutions
https://arxiv.org/abs/1511.07122?utm_source=chatgpt.com

52 71 PyG Documentation — pytorch_geometric documentation
https://pytorch-geometric.readthedocs.io/en/latest/?utm_source=chatgpt.com

53 Representations manual — gudhi v3.12.0 documentation
https://gudhi.inria.fr/python/latest/representations.html?utm_source=chatgpt.com

60 On the locality bias and results in the Long Range Arena
https://arxiv.org/html/2501.14850?utm_source=chatgpt.com

63 statsmodels.stats.contingency_tables.mcnemar
https://www.statsmodels.org/dev/generated/statsmodels.stats.contingency_tables.mcnemar.html?utm_source=chatgpt.com

65 GitHub - open-mmlab/mmsegmentation: OpenMMLab ...
https://github.com/open-mmlab/mmsegmentation?utm_source=chatgpt.com

69 skimage.graph — skimage 0.26.0 documentation
https://scikit-image.org/docs/stable/api/skimage.graph.html?utm_source=chatgpt.com

70 GitHub - MIC-DKFZ/nnUNet
https://github.com/MIC-DKFZ/nnUNet?utm_source=chatgpt.com

72 Transformers · Hugging Face
https://huggingface.co/docs/transformers/index?utm_source=chatgpt.com

73 GitHub - HuXiaoling/TopoLoss: Code for the NeurIPS 2019 ...
https://github.com/HuXiaoling/TopoLoss?utm_source=chatgpt.com